# Seminarska naloga pri predmetu Modeliranje časovnih in prostorskih procesov

# Neža Kržan, Tom Rupnik Medjedovič

# Kazalo

1 A	naliza prostorskega procesa	3
1.	1 Predstavitev podatkov	3
	Vegetacijski indeks NDRE	3
	1.1.1 Grafični prikaz parametrov	4
1.5	1	5
1.3		6
	1.3.1 Razsevni grafikon	6
	1.3.2 Oblak semivariagrama in vzorčni semivariogram	7
	1.3.3 Ovojnice za vzorčni semivariogram	ç
1.4	4 Model semivariograma za dane podatke	10
	1.4.1 Sferični model variograma brez zlatega zrna	10
	1.4.2 Gaussov model variograma brez zlatega zrna	13
Q1•1		
Slik	ie – Ee	
1	Porazdelitev parametrov glede na vrsto	,
$\frac{1}{2}$	Porazdelitev parametrov glede na lokacijo	4
3	Porazdelitev spremenljivke NDRE za mesec julij glede na lokacijo in vrsto.	4
3 4	Grafični prikaz lokacij in relativne vrednosti spremenljivke 'NDRE'	5
4 5	Predstavitev realizacije prostorskega procesa 'NDRE'.	6
6	Prostorska korelacija za 'NDRE(jul)'	-
7	Oblak semivariograma za 'NDRE(jul)'(levo), okvirji z ročaji za vrednosti klasičnega variaograma	1
1	po razdaljah med lokacijami(sredina) in za vrednosti robustnega vzorčnega variograma(desno).	7
0	Vzorčni semivariogram za 'NDRE(jul)'(levo) in za ostanke regresijskega modela (desno)	
8	Vzorčni semivariogram za 'NDRE(jul)'(levo) in za ostanke regresijskega modela (desno)	8
9 10		S S
11	©	10
12	· ·	1(
12		11
13		11
19	podlagi oblaka variograma z ML	11
14		11 12
		12
15		16
10	podlagi oblaka variograma z ML	12
16		16
1 17		13
17	The state of the s	1 .
	podlagi oblaka variograma z ML	14

18	Modela vzorčnega semivariograma za prostorski trend, na podlagi vzorčnega variograma in na	
	podlagi oblaka variograma z ML	14

# Tabele

# 1 Analiza prostorskega procesa

#### 1.1 Predstavitev podatkov

Podatki so bili pridobljeni kot meritev več različnih spremenljivk na izbrani njivi v Šempasu. Podatki tal so pridobljeni 18. 7. 2023 iz globine tal 20 cm, izmerjeni parametri pa so bili:

- swc je gravimetrična vsebnost vode v tleh (vol. %)
- gostota je gostota tal (g/cm3)
- pF2 je vsebnost vode pri matričnem potencialu vode pF 2.0
- pF4.2 je vsebnost vode pri matričnem potencialu vode pF 4.2
- aw je rastlinam razpoložljiva voda v tleh (available water) (pF 2.0 pF 4.2)

Podrobneje bova obravnala vegetacijski indeks NDRE v mesecu juliju in zgoraj napisani izmerjeni parametri lahko, poleg lokacije, tudi vplivajo na vegetacijski indeks.

Na spodnji sliki si lahko ogledamo še načrt meritev.



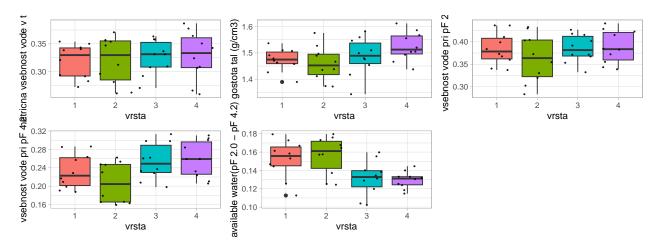
## Vegetacijski indeks NDRE

Vegetacijski indeks NDRE (Normalized Difference Red Edge) je spektralni indeks, ki se uporablja v daljinskem zaznavanju za merjenje vsebnosti klorofila v rastlinah. Pogosto se uporablja v preciznem kmetijstvu za

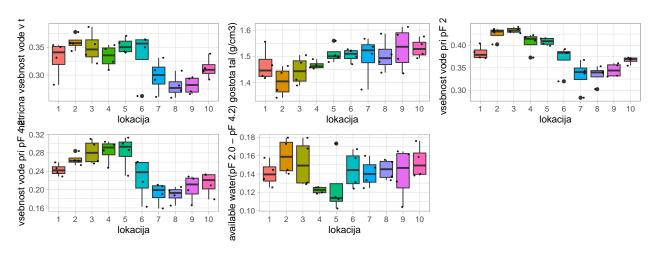
optimizacijo pridelkov, spremljanje zdravja rastlin, določanje potreb po gnojilih in drugih kmetijskih praks. Uporaba tega indeksa omogoča bolj ciljno usmerjene in učinkovite kmetijske posege, kar lahko vodi k večji produktivnosti in trajnosti.

#### 1.1.1 Grafični prikaz parametrov

Najprej si poglejmo s kakšnimi podatki imamo opravka v našem podatkovnem okvirju.

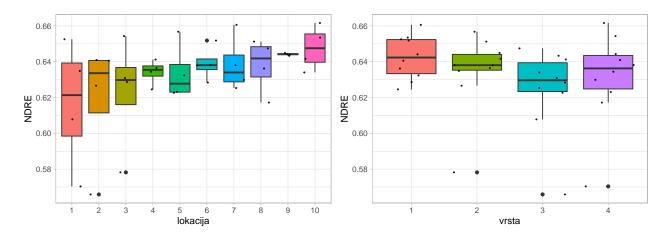


Slika 1: Porazdelitev parametrov glede na vrsto.



Slika 2: Porazdelitev parametrov glede na lokacijo.

Glede na vrsto in lokacijo vidimo, da imajo parametri različne variabilnosti, prav tako je razpon vrednosti, še posebaj glede na lokacijo, zelo različen.

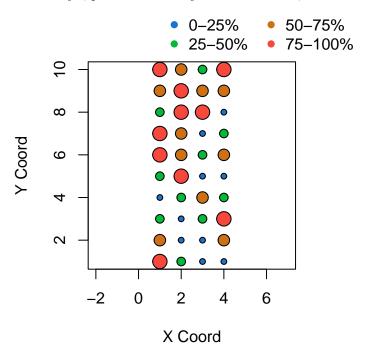


Slika 3: Porazdelitev spremenljivke NDRE za mesec julij glede na lokacijo in vrsto.

Tudi porazdelitve indeksa NDRE se glede na vrsto in lokacijo razlikujejo, njihova variabilnost je različna ter pri določenih vrstah in lokacijah opazimo osamelce ter asimetričnost.

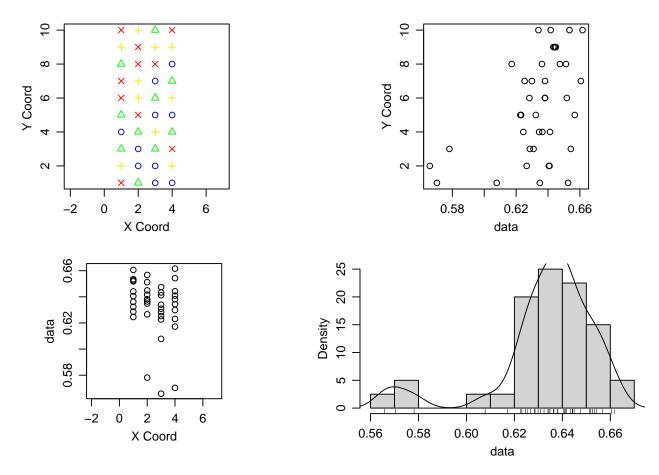
## 1.2 Grafični prikaz

Na spodnjem grafu lahko vidimo lokacije meritev, na katerem sta ploščina in barva krogcev sorazmerna z vrednostjo spremenljivke  $NDRE\_jul$ , podatki so razdeljeni v štiri razrede, ki so določeni s kvantili.



Slika 4: Grafični prikaz lokacij in relativne vrednosti spremenljivke 'NDRE'.

Poglejmo si še nekoliko podrobnejši prikaz, kjer nas bosta zanimala predvsem razsevna grafikona *vrsta* in *NDRE\_jul*, ter *lokacija* in *NDRE\_jul*.



Slika 5: Predstavitev realizacije prostorskega procesa 'NDRE'.

Iz razsevnih grafikonov ni videti odvisnosti spremenljivke *NDRE\_jul* od koordinat lokacije. Iz prvega grafa in pa zgornjega levega grafa lahko opazimo nek vzorec, kar nam nakazuje na prisotnost prostorske korelacije.

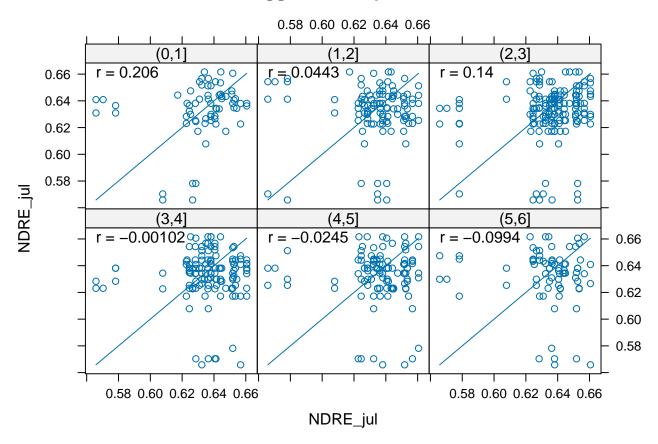
Torej iz zgornjega desnega grafa (vrednosti v odvisnoti od lokacija) in spodnjega levega grafa (vrednosti v odvisnoti od vrsta) ni možno razbrati priostnosti trenda in nekonstantne varinace, zato ne bova naredila podrobnejše analize morebitne nestacionarnosti.

# 1.3 Analiza prostorske korelacije

#### 1.3.1 Razsevni grafikon

Ker naju natančneje zanima izražanje prostorske korelacije, si nariševa razsevne grafikone, na katerih so prikazani pari podatkov na različnih prostorskih odlogih. Črta nam prikazuje idealno povezanost z vrednostjo korelacijskega koeficienta 1.

# lagged scatterplots

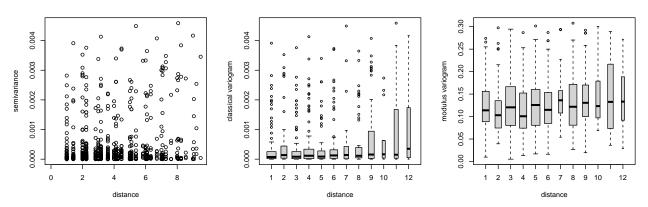


Slika 6: Prostorska korelacija za 'NDRE(jul)'.

Za pare podatkov o **NDRE\_jul** glede na razrede oddaljenosti lahko vidimo, da se z oddaljenostjo prostorska korelacija zmanjšuje (Pearsonov koeficient korelacije). Lahko bi torej reki, da na zelo kratkih razdaljah imamo majhno povezanost, ki na daljših razdaljah še pada.

#### 1.3.2 Oblak semivariagrama in vzorčni semivariogram

Poglejmo analizo prostorske korelacije še s pomočjo oblaka semivariograma in vzorčnega semivariograma.

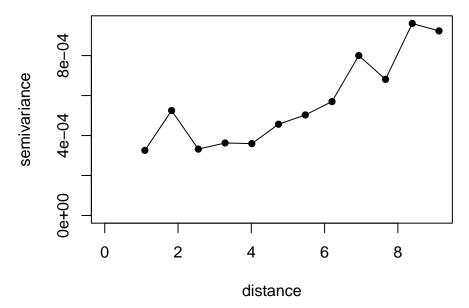


Slika 7: Oblak semivariograma za 'NDRE(jul)'(levo), okvirji z ročaji za vrednosti klasičnega variaograma po razdaljah med lokacijami(sredina) in za vrednosti robustnega vzorčnega variograma(desno).

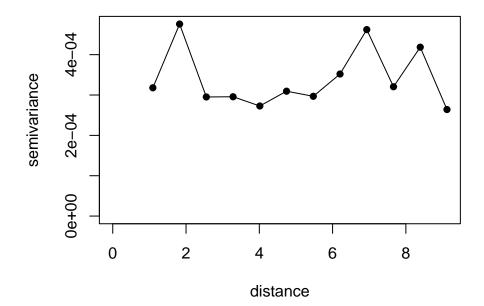
Na skrajno levem zgornjem grafu vidimo, da vrednosti  $NDRE\_jul$  predstavljajo meritve v pravilni mreži točk, saj oblak variograma prikazuje diskretne vrednosti razdalj med lokcijami in so točke narisane v črtah. Porazdelitve vrednosti vzorčnega variograma pa so asimetrične v vsakem razredu(razredi predstavljajo razdalje), prav tako pa imamo nekaj osamelcev. Na zadnjem, robustnem vzorčnem variogramu, kjer na nek način "posekamo" vpliv vrednosti, ki zelo odstopajo, vidimo, da so porazdelitve glede na razrede sedaj bistveno drugačne in nekateri osamelci izginejo.

Na spodnjem levem vzorčnem semivariogram s povprečji za posamezne razrede razdalje lahko iz razporeditve točk razberemo, da so pri manjših razdaljah vzorčne variogramske vrednosti manjše, z naraščajočo razdaljo se povečujejo in se z nadaljnjim večanjem razdalje ne ustalijo ravno oz. ne izgleda, kot da bi se približevale določenemu pragu, torej kaže na prisotnost prostorskega trenda v podatkih.

Vzorčni variogram za ostanke prostorskega trenda(desno) pokaže, da je prostorska korelacija med ostanki precej šibkejša.

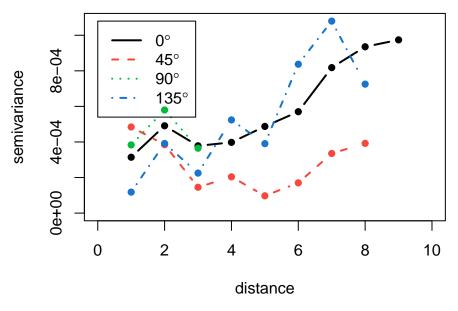


Slika 8: Vzorčni semivariogram za 'NDRE(jul)'(levo) in za ostanke regresijskega modela (desno).



Slika 9: Vzorčni semivariogram za 'NDRE(jul)'(levo) in za ostanke regresijskega modela (desno).

Do sedaj sva proučevala prostorsko korelacjo ne glede na smer v prostoru, torej sva predpostavila izotropni prostorski proces. Zato narišimo še usmerjene semivariograme za določene smeri v prostoru in s tem preverimo ali je predpostavka izotropnosti upravičena.



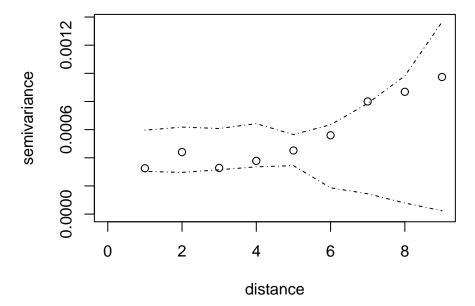
Slika 10: Vzorčni variogrami za 'NDRE(jul)' za štiri glavne smeri.

Vzorčni variogrami za  $NDRE\_jul$  za štiri glavne smeri izraža izotropijo, saj že na krajših razdaljah vidimo razlike v vzorčnih variogramih za različne smeri. Torej bi glede na graf bilo potrebno modeliranje prostorske korelacije na kratke razdalje.

#### 1.3.3 Ovojnice za vzorčni semivariogram

Da bi dobila širšo sliko o prostorski povezanosti procesa, pri raziskovanju prostorske povezanosti uporabiva Monte Carlo simulacije na podlagi te realizacij prostorskega procesa. Če padejo vse vrednosti osnovnega

vzorčnega variograma znotraj ovojnice, ki je določena z robnima variogramoma permutiranih vrednosti, potem podatki ne nakazujejo prostorske povezanosti. Predvsem naju zanima nekaj prvih točk, ki odražajo korelacijo na manjših razdaljah.



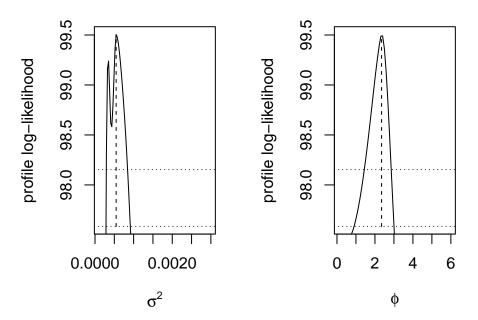
Slika 11: Monte Carlo ovojnica semivariograma.

Vidimo, da ni izrazite koreliranosti oz. podatki niso prostorsko korelirani.

## 1.4 Model semivariograma za dane podatke

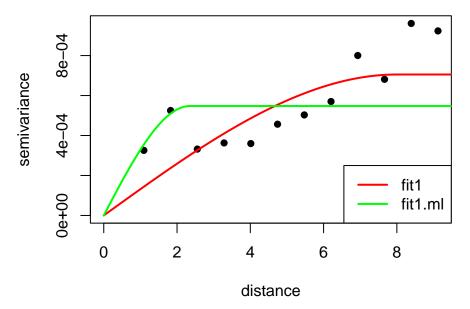
#### 1.4.1 Sferični model variograma brez zlatega zrna

Najprej sva parametre semivariograma ocenila z metodo Maximum Likelihood(ML), ki za začetne vrednosti vzame ocene dobljene s funkcijo variofit.



Slika 12: Profile-log-likelihood za parametra sferičnega modela semivariograma brez zlatega zrna kaže na napačno izbiro modela prostorske korelacije.

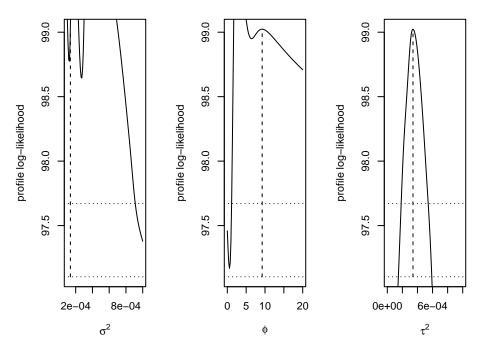
Izgleda kot da po metodi največjega verjetja z začetnimi vrednostmi praga in razmika variograma **fit1** dobimo optimalne rešitve za parametre semivariograma.



Slika 13: Modela vzorčnega semivariograma za prostorski trend, na podlagi vzorčnega variograma in na podlagi oblaka variograma z ML.

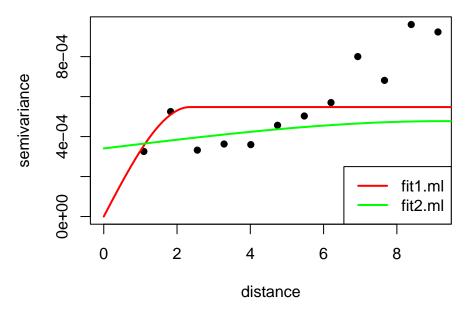
Vidimo, da z modelom fit1.ml kjer smo kot metodo uporabili ML, nekoliko bolje opisali vrednosti semivarianc za manjše razdalje. V celoti pa bi lahko rekli da z modelom fit1 bolje opišemo vrednosti semivarianc za razdalje od 1 do 10.

V naslednjem koraku pri uporabi funkcije likfit dopustiva,da dobimo tudi oceno za zlato zrno.



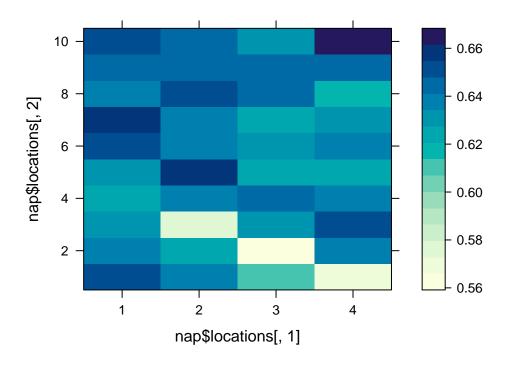
Slika 14: Profile-log-likelihood za parametre sferičnega modela semivariograma z zlatim zrnom.

Iz grafov lahko vidimo da po metodi največjega verjetja z začetnimi vrednostmi praga in razmika variograma fit1 ne dobimo optimalne rešitve za  $\sigma^2$  (prag semivariograma-sill) in  $\phi$  (razmik-range). Le za  $\tau$  (varianca zlatega zrna) dobimo optimalno rešitev. To nakazuje na napačno izbiro modela prostorske korelacije.



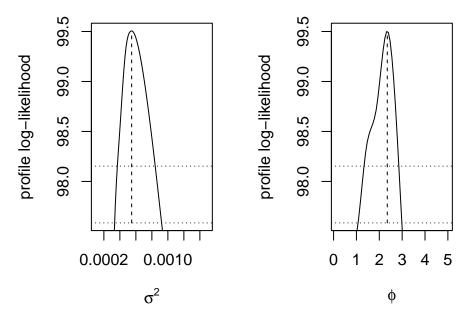
Slika 15: Modela vzorčnega semivariograma za prostorski trend, na podlagi vzorčnega variograma in na podlagi oblaka variograma z ML.

Če med seboj primerjamo modela, pri katerem je vrednost zlatega zrna fiksna (rdeča) in model pri katerem ocenjujemo vrednost zlatega zrna (zelena). Izkaže se, da v primeru fiksne vrednosti zlatega zrna bolje opišemo vrednosti semivarianc za manjše razdalje.



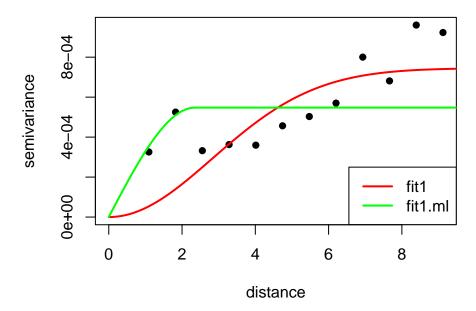
#### 1.4.2 Gaussov model variograma brez zlatega zrna

Poskusila bova modelirati še z uporabo Gaussove kovariančne funkcije. Preverila bova ali z uporabo metode ML dobimo boljše prileganje vrednostim variograma.



Slika 16: Profile-log-likelihood za parametra Gaussovega modela semivariograma brez zlatega zrna kaže na napačno izbiro modela prostorske korelacije.

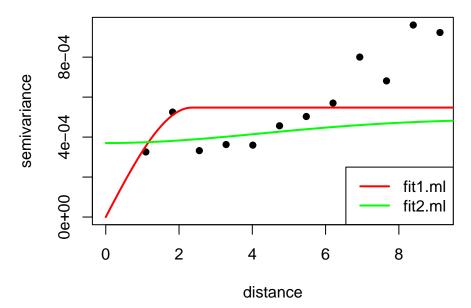
Izgleda kot da po metodi največjega verjetja z začetnimi vrednostmi praga in razmika variograma  ${\bf fit1}$ \_ ${\bf g}$  dobimo optimalne rešitve za parametre semivariograma.



Slika 17: Modela vzorčnega semivariograma za prostorski trend, na podlagi vzorčnega variograma in na podlagi oblaka variograma z ML.

Ponovno vidimo, da z uporabo metode ML, torej modelom fit1.ml bolje opišemo le prvi dve vrednosti vzorčnega semivariograma. Z modelom fit1 pa bolje opišemo vrednosti tudi pri večjih razdaljah.

V naslednjem koraku pri uporabi funkcije likfit dopustiva,da dobimo tudi oceno za zlato zrno.



Slika 18: Modela vzorčnega semivariograma za prostorski trend, na podlagi vzorčnega variograma in na podlagi oblaka variograma z ML.

Če med seboj primerjamo modela, pri katerem je vrednost zlatega zrna fiksna (rdeča) in model pri katerem ocenjujemo vrednost zlatega zrna (zelena). Izkaže se, da v primeru fiksne vrednosti zlatega zrna bolje opišemo vrednosti semivarianc za manjše razdalje.

